

Clasificación de Lesiones Cutáneas

Un enfoque jerárquico y contrastivo para la detección de lesiones malignas

A detailed microscopic image of skin tissue. In the center, a large, spherical, pinkish-red structure with numerous thin, hair-like projections (microvilli) extends from its surface, representing a cancerous growth. The surrounding tissue consists of various other cells and structures in shades of orange and red, some appearing as smaller, more rounded cells.

Introducción

Detección Temprana: Clave contra el Cáncer de Piel

Cáncer de Piel

Uno de los cánceres más frecuentes, con el melanoma como variante más agresiva.

Diagnóstico Manual

Desafíos por similitud visual, variabilidad entre especialistas y necesidad de experiencia.

Aprendizaje Profundo



Técnicas prometedoras para automatizar la clasificación, mejorando la precisión.

Disponibilidad Especialistas

En muchas regiones, el acceso a dermatólogos y oncólogos especializados es escaso

Metodología


HAM1000



Metodología

HAM1000

Benignas: 7919
Malignas: 2096




Lesión queratósica 1099



Dermatofibroma 115



Nevus 6705




Lesiones vasculares 142



Carcinoma epidermoide 327



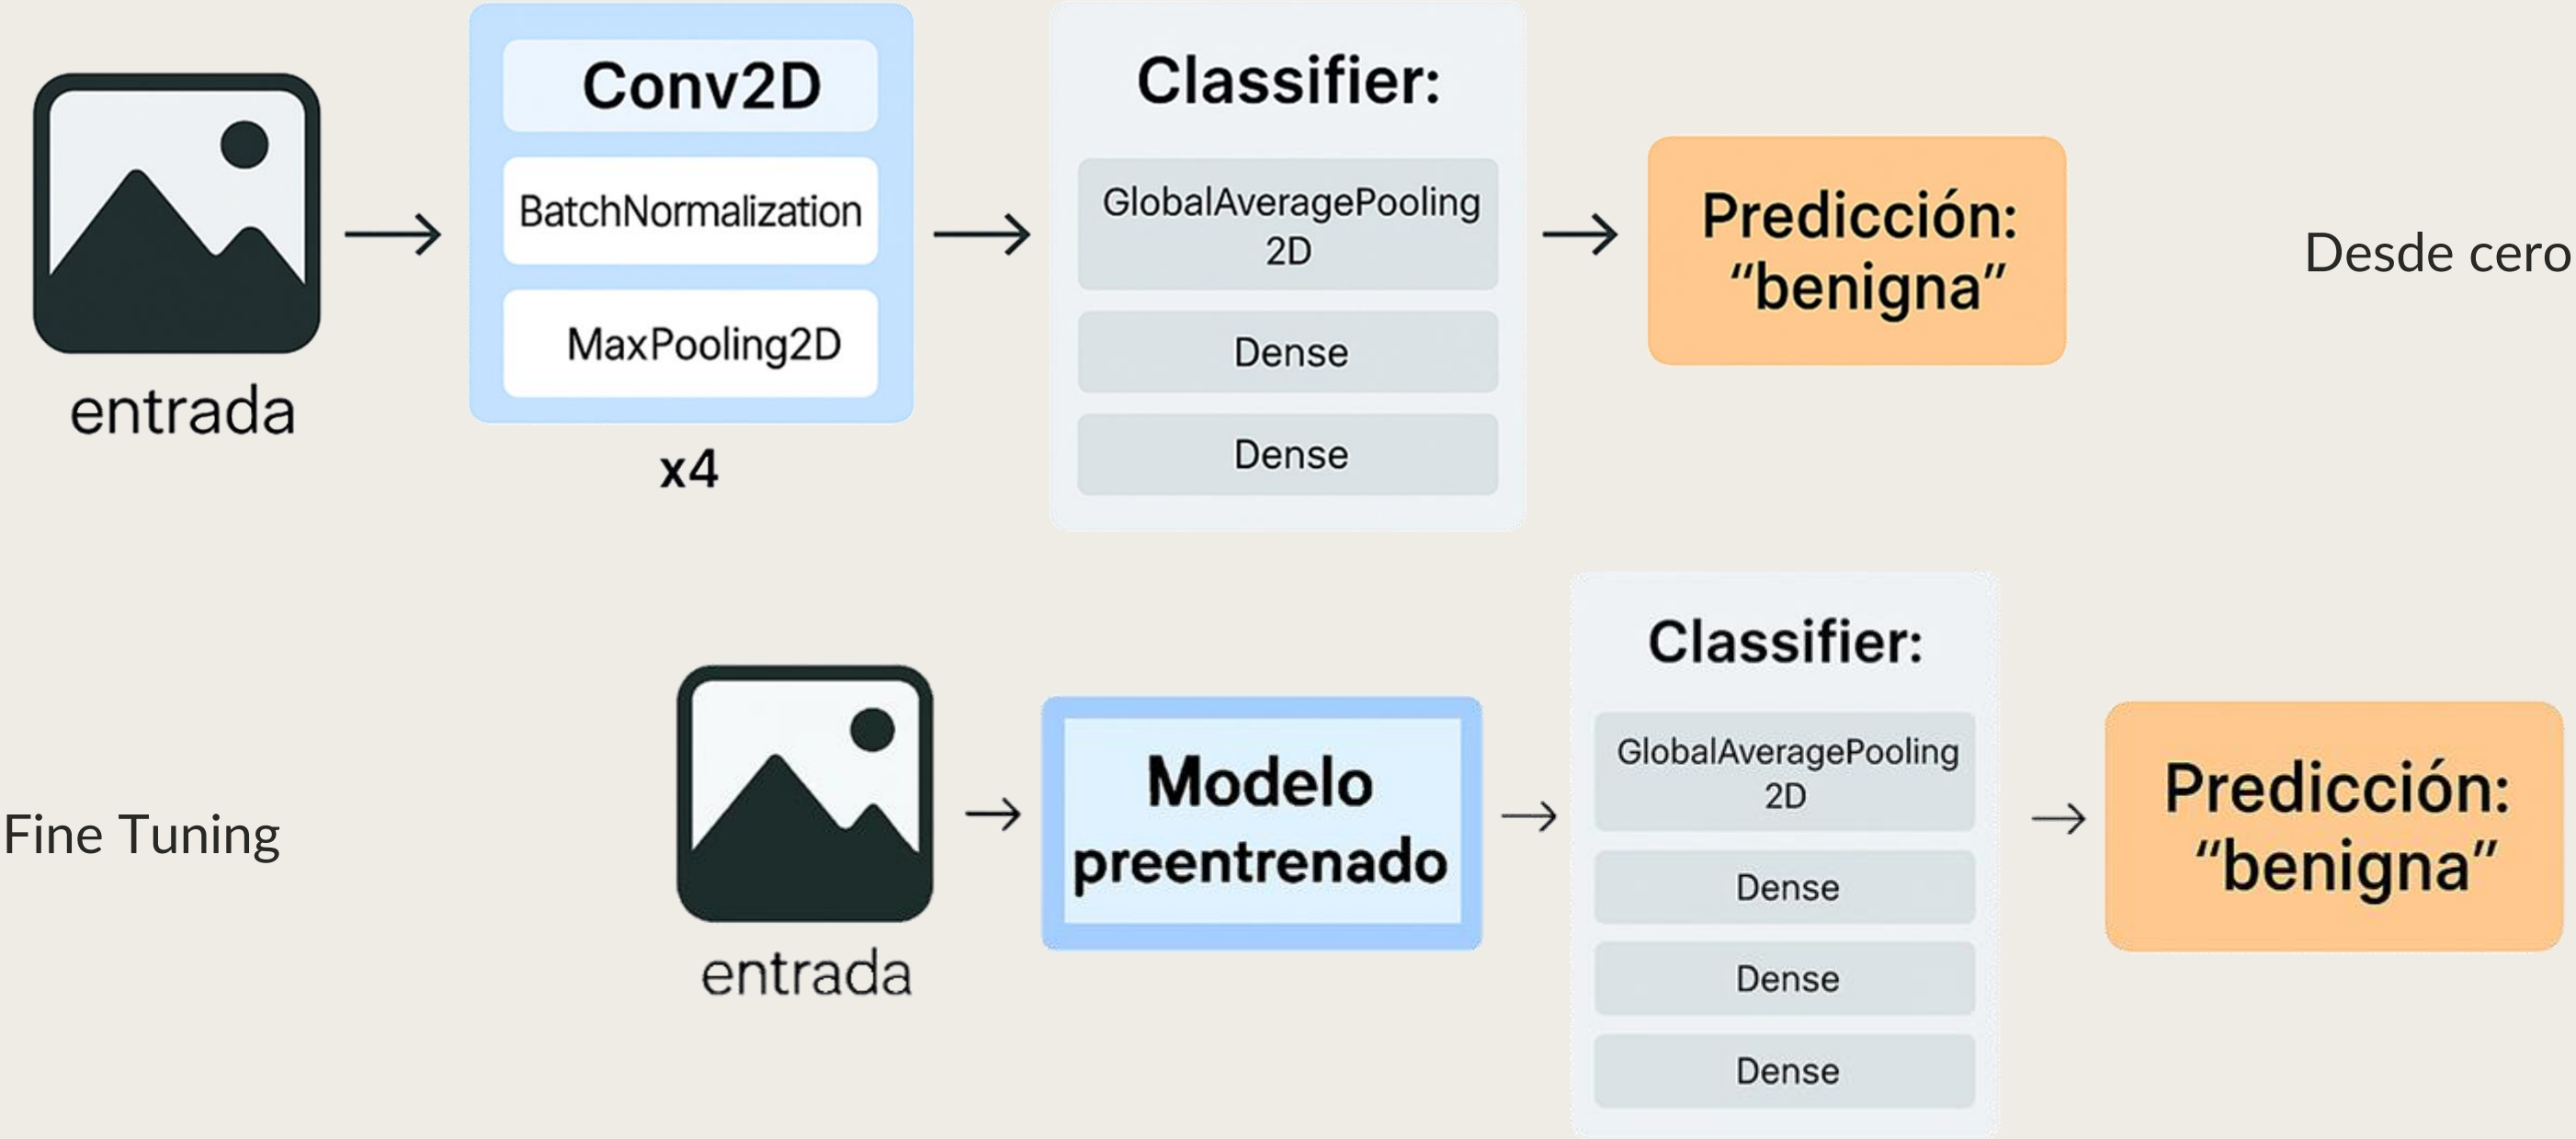
Carcinoma basocelular 514



Melanoma 1113

Metodología

Modelos



Clasificación Binaria y Maligna



Entrenamiento desde Cero

No satisfactorio debido a la complejidad visual de las lesiones.



Transfer Learning

Modelos preentrenados (VGG16, ResNet50, InceptionV3) mejoraron la precisión.



Balanceo de Clases


Técnicas de reponderación y aumento de datos para mitigar el desequilibrio.

Metodología

Clasificación entre Malignas

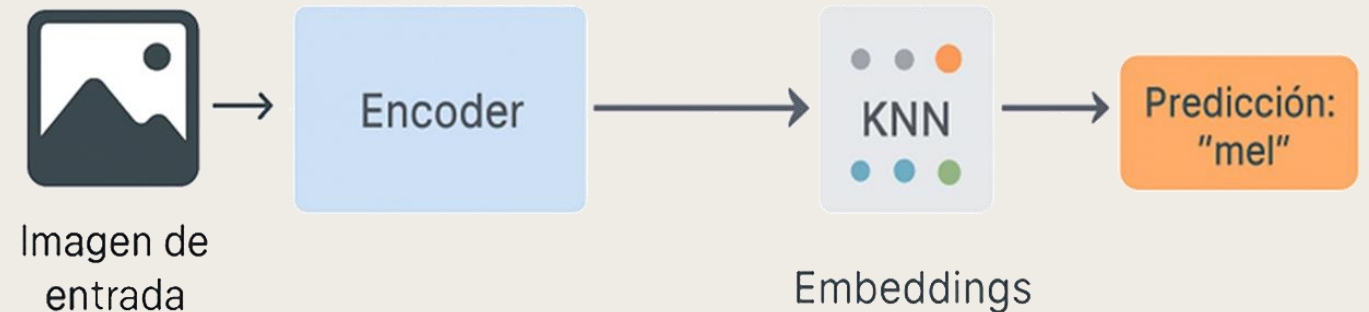
Contrastivo por Pares

Minimiza distancia entre pares positivos, maximiza entre negativos.




Contrastivo Supervisado

Aprovecha el contexto del batch para embeddings discriminadores (SupConLoss).



No Contrastivo

Pérdida de entropía cruzada estándar como referencia.



Metodología

Función de Pérdida SupConLoss

La pérdida SupConLoss utiliza las etiquetas de clase para mejorar la separación de características en el espacio de embeddings, agrupando las muestras de la misma clase y separándolas de las de clases diferentes. Este enfoque mejora la robustez y discriminación de los modelos.

1. Normalizamos los embeddings

$$\tilde{z}_i = \frac{z_i}{\|z_i\|_2}$$

2. Similitud entre 2 embeddings

$$S_{ij} = \frac{z_i z_j}{\tau} \quad S \in \mathbb{R}^{B \times B}$$

3. Mascara binaria

$$M_{ij} = \begin{cases} 1 & \text{si } y_i = y_j \text{ y } i \neq j \\ 0 & \text{si no} \end{cases}$$

4. Pérdida por muestra en el batch

$$l_i = -\frac{1}{|P(i)|} \sum_{j \in P(i)} \log \left(\frac{\exp(S_{ij})}{\sum_{k \neq j} \exp(S_{ik})} \right)$$


5. Pérdida total del batch

$$L_{\text{SupCon}} = \frac{1}{B} \sum_{i=1}^B l_i$$

Resultados

Comparación de Rendimiento Final

El pipeline jerárquico supera al modelo multiclase directo, ofreciendo un mejor rendimiento y flexibilidad para nuevas clases malignas.



Resultados

Comparación de Rendimiento Final

Resultado final

Modelo	F1-score
Pipeline	0.76
Modelo convolucional	0.72

Clasificación entre clases malignas

Modelo	F1-score
Contrastivo supervisado	0.80
No contrastivo	0.80


Clasificación binaria

Modelo	F1-score
Desde cero	0.76
VGG16	0.87
ResNet50	0.83
InceptionV3	0.79

Resultados



Visualización de Embeddings

El aprendizaje contrastivo supervisado mejora la discriminación entre clases, pero sigue siendo limitado para las categorías minoritarias, probablemente por la poca profundidad del modelo o el tamaño reducido del batch.




Resultados

Visualización de Grad-CAM



Conclusiones

Impacto y Futuro del Diagnóstico Asistido



Rendimiento Superior

El pipeline jerárquico mejora la detección de lesiones malignas, crucial en la práctica dermatológica.

Interpretabilidad

Grad-CAM refuerza la utilidad clínica, permitiendo a especialistas validar predicciones.

Flexibilidad

El aprendizaje contrastivo supervisado y KNN ofrecen flexibilidad para nuevas clases malignas.

Próximos Pasos

Explorar few-shot learning y validar en otros datasets para mayor robustez.